



一、QLoRA 高效微调量化大模型 00:05

1. QLoRA介绍 00:33



- **核心创新：**提出量化低秩适配器方法，在单个48GB GPU上实现650亿参数模型的微调
- **性能保持：**采用4-bit量化同时保持16-bit微调任务的性能（论文中"sixteen bit finetuning task performance"）
- **技术原理：**通过冻结的int4量化预训练语言模型反向传播梯度到低秩适配器(LoRA)实现微调
- **三大优化技术：**
 - 新型数据类型：4-bit NormalFloat(NF4)
 - 双量化技术(Double Quantization)
 - 分页优化器(Paged Optimizer)，类似DeepSpeed的Zero Offload技术

2. 不同微调方法及其内存要求 02:53



1) 全精度微调中的模型结构 03:08

- **层级结构：**
 - 基础模型(Base Model)：16-bit精度加载（如float16）
 - 适配器(Adapters)：16-bit精度
 - 优化器状态(Optimizer State)：32-bit精度（float32）
- **显存消耗：**优化器参数通常是基础模型的3-6倍（因需存储参数副本和超参数）

2) LoRA微调方法介绍 03:57

- **核心改进：**

- 冻结基础模型参数 (16-bit Transformer)
- 仅微调低秩适配器 (参数量约为原模型1‰)
- **显存优势:**
 - 优化器状态量减少至适配器参数的6倍
 - 总体显存需求从"7倍模型大小"降至"7‰模型大小"

3) LoRA与Full Finetuning的对比 04:08

- **参数更新方式:**
 - Full Finetuning: 全量参数梯度更新
 - LoRA: 仅更新适配器参数 (ΔW)
- **精度保持:**
 - 两者均保持16-bit计算精度
 - LoRA通过小规模参数调整实现近似全量微调效果

4) QLoRA微调方法及其优化 05:46


- **量化突破:**
 - 基础模型采用4-bit量化 (相比原16-bit显存减少75%)
 - 示例: 20GB模型→5GB显存占用
- **双量化技术:**
 - NF4数据类型优化量化效率
 - 配合适配器微调达到最佳效果 (图示绿色曲线)

5) QLoRA中的分页存储技术 06:52

- **动态加载机制:**
 - 当前计算阶段需要的适配器才加载到GPU
 - 其余适配器暂存CPU内存 (类似Zero Offload技术)
- **分页优化器:**
 - 按需分页交换GPU/CPU间的优化器状态
 - 显著降低峰值显存需求

3. 数据类型补充 07:08

1) 经典浮点数格式



- **Float32结构:** 1位符号位 + 8位指数位 + 23位尾数位
- **Float16结构:** 1位符号位 + 5位指数位 + 10位尾数位
- **Float8变体:**
 - E4M3: 1位符号位 + 4位指数位 + 3位尾数位
 - E5M2: 1位符号位 + 5位指数位 + 2位尾数位
- **精度特性:**

- Float32的有效精度最长（23位尾数）
- Float8的E5M2版本表达范围更大但精度更低（如可表达±100万但小数点后仅3位）
- Float8的E4M3版本表达范围较小但精度更高（如±1万范围但小数点后5位）

2) 4-bit NormalFloat介绍 09:06

● 量化基础原理

极客时间

QLoRA 提出新数据类型 4-bit NormalFloat (NF4)

8-bit 量化 $X^{int8} = \text{round}\left(\frac{127}{\text{absmax}(X^{FP32})} X^{FP32}\right) = \text{round}(c^{FP32} \cdot X^{FP32})$

量化常数 $c = \frac{127}{\text{absmax}(X^{FP32})}$

反量化 $X^{FP32} = \frac{X^{int8}}{c}$

NormalFloat (NF) 数据类型建立在分位数量化之上，Quantile quantization 是一种信息论最优的数据类型，可确保每个量化 bin 具有从输入张量分配的相同数量的值。

分位数量化的工作原理是通过经验累积分布函数估计输入张量的分位数，主要限制是分位数估计的过程是昂贵的。因此，快速分位数近似算法，如SRAM分位数，常被用来估计它们。

由于预训练的神经网络权重通常具有标准差为 σ 的零中心正态分布，可以通过缩放 σ 将所有权重转换为单个固定分布，以便分布恰好符合我们数据类型的范围。

免费获取课程资料
微信号: kehuowan.com

-
- Int8量化示例：
 - 表达范围：-128到127（256个整数值）
 - 量化公式： $X^{int8} = \text{round}\left(\frac{127}{\text{absmax}(X^{FP32})} X^{FP32}\right)$
 - 反量化公式： $X^{FP32} = \frac{X^{int8}}{c^{FP32}}$
- 分位数量化：
 - 信息论最优的数据类型
 - 确保每个量化区间包含相同数量的输入值
 - 通过经验累积分布函数估计分位数
 - 计算瓶颈：分位数估计过程计算量大，需采用SRAM等快速近似算法

● NF4实现细节

极客时间

QLoRA 提出新数据类型 4-bit NormalFloat (NF4)

在神经网络中，预训练的权重通常具有零中心的正态分布，标准差为 σ 。通过缩放 σ ，可以使分布恰好适应NF的范围。对于NF，作者设置了一个任意的范围[-1, 1]。因此，数据类型和神经网络权重的分位数都需要被归一化到这个范围。

范围[-1, 1]中具有任意标准差 σ 的零均值正态分布的信息论最优数据类型计算如下：

1. 估计理论N(0,1)分布的 2^k+1 分位数，得到正态分布的k位分位数量化数据类型；
2. 采用这种数据类型并将其值归一化到[-1,1]范围内；
3. 通过绝对最大缩放将其归一化到[-1,1]范围内来量化输入权重张量。

一旦权重范围和数据类型范围匹配，我们就可以像往常一样量化。步骤(3)相当于重新缩放权重张量的标准差以匹配k位数据类型的标准差。更正式地说，我们估计数据类型的 2^k 值 q_i 如下：

$$q_i = \frac{1}{2} \left(Q_X \left(\frac{i}{2^k+1} \right) + Q_X \left(\frac{i+1}{2^k+1} \right) \right)$$

其中 $Q_X(\cdot)$ 是标准正态分布 $N(0, 1)$ 的分位数函数。

论文将具有每个量化区间中预期相等数量值的结果数据类型称为 k-bit NormalFloat(NFk)

免费获取课程资料
微信号: kehuowan.com

-
- 核心假设：
 - 预训练权重服从零均值正态分布 $N(0, \sigma^2)$
 - 通过缩放 σ 使分布适配NF4范围[-1, 1]
- 实现步骤：
 - 计算标准正态分布 $N(0, 1)$ 的 $2^k + 1$ 分位数
 - 将分位数归一化到[-1, 1]范围
 - 通过绝对最大缩放量化输入权重

分位数计算公式：

$$q_i = \frac{1}{2} \left(Q_X \left(\frac{i}{2k+1} \right) + Q_X \left(\frac{i+1}{2k+1} \right) \right)$$

- 其中 $Q_X(\cdot)$ 为标准正态分布的分位数函数
- 扩展性:
 - NfK中的k表示位数 (如NF4为4-bit)
 - 分位数数量随k指数增长 (NF4为17个, NF5为33个)
 - 当数据分布范围过大时可升级到更高位数 (如NF8)

4. 双量化技术 17:24

极客时间

QLoRA 提出双量化技术: 量化 (量化常数)

QLoRA 模型 $\mathbf{Y}^{BF16} = \mathbf{X}^{BF16} \text{doubleDequant}(c_1^{FP32}, c_2^{k-bit}, \mathbf{W}^{NF4}) + \mathbf{X}^{BF16} \mathbf{L}_1^{BF16} \mathbf{L}_2^{BF16}$

$\text{doubleDequant}(c_1^{FP32}, c_2^{k-bit}, \mathbf{W}^{k-bit}) = \text{dequant}(\text{dequant}(c_1^{FP32}, c_2^{k-bit}), \mathbf{W}^{4bit}) = \mathbf{W}^{BF16}$

QLoRA 设计了一个存储数据类型 (4-bit NormalFloat) 和一个计算数据类型 (16-bit BrainFloat)。

QLoRA 将权重从存储数据类型反量化为计算数据类型, 以执行前向和后向传播, 但仅计算 16-bit BrainFloat 的 LoRA 参数的权重梯度。

权重仅在需要时才解压缩, 因此在训练和推理期间内存使用率都能保持较低水平。

免费获取海量资源
微信号: kehuaiwan.net

- 实现原理: 通过两次量化过程实现, 第一次量化使用FP32常数 c_1^{FP32} , 第二次量化使用k-bit常数 c_2^{k-bit} , 最终将4-bit权重 $\mathbf{W}^{NF4}$ 解量化为BF16格式 $\mathbf{W}^{BF16}$
- 计算过程: $\mathbf{Y}^{BF16} = \mathbf{X}^{BF16} \text{doubleDequant}(c_1^{FP32}, c_2^{k-bit}, \mathbf{W}^{NF4}) + \mathbf{X}^{BF16} \mathbf{L}_1^{BF16}$
- 存储与计算分离:
 - 存储数据类型: 4-bit NormalFloat(NF4)
 - 计算数据类型: 16-bit BrainFloat(BF16)
- 动态解压缩: 仅在需要时解压缩权重, 训练和推理期间保持低内存使用率
 - 前向/反向传播时解压为BF16
 - 仅计算LoRA参数的16-bit梯度
 - 更新后重新量化为NF4存储

5. 实验结果 19:30

1) 不同数据类型在benchmark上的表现 19:32

极客时间

QLoRA 实验结果

Table 3: Experiments comparing 16-bit BrainFloat (BF16), 8-bit Integer (Int8), 4-bit Float (FP4), and 4-bit NormalFloat (NF4) on GLUE and Super-NaturalInstructions. QLoRA replicates 16-bit LoRA and full-finetuning.

Dataset Model	GLUE (Acc.) RoBERTa-large	Super-NaturalInstructions (RougeL)				
		T5-80M	T5-250M	T5-780M	T5-3B	T5-11B
BF16	88.6	40.1	42.1	48.0	54.3	62.0
BF16 replication	88.6	40.0	42.2	47.3	54.9	-
LoRA BF16	88.8	40.5	42.6	47.1	55.4	60.7
QLoRA Int8	88.8	40.4	42.9	45.4	56.5	60.7
QLoRA FP4	88.6	40.3	42.4	47.5	55.6	60.9
QLoRA NF4 + DQ	-	40.4	42.7	47.7	55.3	60.9

免费获取海量资源
微信号: kehuaiwan.net

- 性能对比:
 - NF4+DQ: 在RoBERTa-large上达到88.6%准确率, 与BF16(88.6%)持平
 - FP4: 在T5-11B上RougeL为60.9, 略低于NF4+DQ(60.9)和BF16(62.0)

- Int8: 在T5-3B上表现最差(55.4), 比NF4+DQ(55.3)略优
- 2) 三大量化技术的效果比较 19:58

- 技术叠加效果:
 - BF16单独使用已接近NF4+DQ效果
 - 完整量化技术组合(双量化+NF4)效果最佳
- 显存优化:
 - 基础模型加载仅需1/4显存
 - 训练过程通过双量化进一步降低显存需求

3) QLoRA实验结果概述 20:44

极客时间

QLoRA 实验结果

Table 4: Mean 5-shot MMLU test accuracy for LLaMA 7-65B models finetuned with adapters on Alpaca and FLAN v2 for different data types. Overall, NF4 with double quantization (DQ) matches BFloat16 performance, while FP4 is consistently one percentage point behind both.

LLaMA Size Dataset	Mean 5-shot MMLU Accuracy								Mean
	7B		13B		33B		65B		
	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	Alpaca	FLAN v2	
BFloat16	38.4	45.6	47.2	50.6	57.7	60.5	61.8	62.5	53.0
Float4	37.2	44.0	47.3	50.0	55.9	58.5	61.3	63.3	52.2
NFloat4 + DQ	39.0	44.5	47.5	50.7	57.3	59.2	61.8	63.9	53.1

免费获取海量资源
微信号: kehuaiwan.net



- 模型规模适应性:
 - 7B-65B模型均适用, NF4+DQ在65B模型达到63.9准确率
 - 平均表现: NF4+DQ(53.1) > BF16(53.0) > FP4(52.2)
- 性能匹配:
 - NF4+DQ完全匹配BF16性能
 - FP4始终落后约1个百分点

4) QLoRA的通用性与资源消耗降低 21:22

- 架构无关性:
 - 兼容原有LoRA/Adapter架构
 - 不改变模型网络结构
- 资源优化:
 - 使普通用户可微调十亿级模型
 - 支持混合精度训练(BF16)
 - 结合GPU/CPU卸载功能进一步优化显存使用

二、知识小结

知识点	核心内容	技术亮点/易混淆点	难度系数
QLoRA量化机制	在LoRA基础上增加量化技术, 优化模型硬件侧的存储格式和数据类型	4bit NormalFloat(NF4)新数据类型; 双量化技术; 分页优化器(paged optimizer)	★★★★
量化数据类型对比	float32(全精度)→float16(半精度)→int8→NF4(4bit)	NF4通过分位数量化保持分布特性; 关键公式: 量化值 = 127/abs(max)*fp32;	★★★★

		反量化需除以量化常数	
NF4技术原理	基于权重符合正态分布的特性，通过缩放标准差匹配预置分位数	快速分位数近似算法(SRM) ；分位数计算公式： 2^{k+1} ；负一到正一的归一化范围	★★★★★
双量化技术	对量化常数进行二次量化，实现存储计算分离	基础模型用 NF4 存储；计算时解量为 16bit BrainFloat ；动态加载机制	★★★★
资源优化效果	48GB显存可微调650亿参数模型	基础模型显存消耗降为 1/4 ；优化器参数量减少99.9%；与 DeepSpeed Zero Offload 技术协同	★★★
性能实验数据	在7B/65B模型上测试	NF4+双量化 效果最优；bf16方案接近NF4效果；绿色曲线显示最佳收敛性	★★★★
技术通用性	与模型架构解耦	兼容原有 LoRA/Adapter 方案；不改变网络结构；支持混合精度训练	★★★